

근거 오염 환경에서 RAG의 응답 강건성과 기권 기반 방어기법에 관한 연구

박정원¹, 안솔은², 서현우³, 이동현⁴, 이규영⁵

¹ 경북대학교 전자공학부 인공지능전공 학부생

² 부경대학교 국제통상학부 국제통상학전공 학부생

³ 한국해양대학교 물류시스템공학과 학부생

⁴ 홍익대학교 기계시스템디자인공학과 학부생

⁵ 제주한라대학교 인공지능학과 교수

mbb11974@gmail.com, Thfdmss5207@naver.com, line51015@naver.com, jn3790@g.hongik.ac.kr,
onlyai@chu.ac.kr

Response Robustness and Abstention-Based Defense for RAG under Evidence Contamination

Jeongwon Park¹, Soleun An², Hyeonwoo Seo³, Donghyun Lee⁴, Gyuyoung Lee⁵

¹Dept. of Artificial Intelligence, School of Electronics Engineering, Kyungpook National University

²Division of International Commerce, Pukyong National University

³Dept. of Logistics System Engineering, Korea Maritime and Ocean University

⁴Dept. of Mechanical System Design Engineering, Hongik University

⁵Dept. of Artificial Intelligence, Cheju Halla University

요 약

검색증강생성(RAG)은 대규모 언어모델(LLM)의 환각을 줄이는 대표적 방법으로 활용되지만, 검색이 부적절한 근거를 반환할 경우 오히려 LLM이 이를 신뢰하여 더 위험한 오답을 생성할 위험이 있다. 본 연구에서는 한국어 향만 안전 규정 도메인에서의 환각 취약성을 정량화하고, 기권을 유도하는 프롬프트가 취약성을 완화하는지 검증하였다.

1. 서론

RAG는 LLM이 외부 문서를 검색해 근거로 삼게 함으로써 환각(hallucination)을 줄이는 방법으로 널리 쓰인다[1]. 그러나 검색 결과에 부정확하거나 질문에 맞지 않는 근거가 섞여 들어오는 상황은 향만 안전처럼 오답이 사고로 이어질 수 있는 안전 임계 도메인에서 중요한 문제로 대두될 수 있다.

선행 연구에 따르면 LLM은 질문과 무관한 문맥이 주어지면 쉽게 주의가 분산되고[2], 외부 근거가 자신의 내부 지식과 충돌하더라도 일관성 있게 제시되면 이를 쉽게 수용한다[3]. RAG는 답을 포함하지 않는 관련 문서(노이즈)의 비율이 높아질수록 정확도가 하락하고, 필요한 근거가 전혀 없을 때에도 LLM이 기권하지 못하는 경우가 많음을 보고하였다[4]. 또한 지식 데이터베이스에 소수의 악의적 문서를 주입하는

것만으로 RAG의 응답을 조작할 수 있음이 밝혀졌으며[5], 모델이 답을 모를 때 추측 대신 답변을 유보하는 기권(abstention)이 환각을 줄이는 방법으로 연구되고 있다[6]. 그러나 기존 연구는 주로 일반 도메인의 영어·중국어 데이터를 대상으로 하였으며, 같은 규정 문서 안에서 항목명과 서술 형식은 거의 같고 수치만 다른 실재 조항이 근거로 섞이는 상황은 충분히 다루어지지 않았다.

본 연구는 근거 오염의 양이 늘어날 때 LLM의 오답률이 어떻게 변하는가와 “근거에서 확인할 수 없으면 기권하라”는 지시문이 이 위험을 얼마나 완화하는지를 분석하며, 이를 위해 응답을 정답·근거초과·기권·오답의 4가지로 구분한다. 본 논문의 기여는 다음과 같다. 첫째, 한국어 향만 안전 규정 문서에서 같은 문서 안의 수치 충돌 조항을 오염 근거로 사용하

고, 정답 근거를 고정한 채 오염 수준을 단계적으로 높이는 실험 설계를 제시하였다. 둘째, 정답 근거가 남아 있는 한 오염 조항을 최대 4 개까지 주입해도 오답률이 5% 미만에 머물고, 위험은 정답 근거가 누락된 구간에 집중됨을 정량적으로 확인하였다. 셋째, 기권 유도 프롬프트가 전량 오염 구간의 오답률을 낮추지만 정상 검색 구간에서는 정답률 손실과 불필요한 기권을 유발함을 4 분류 채점으로 밝혀, 조건부 적용의 필요성을 제시하였다.

2. 제안 방법론

가. 단계적 부분오염

질문마다 근거 5 개 슬롯 중 1 개를 정답 조항으로 항상 고정하고, 나머지 4 개를 오염 수준(L0~L4)에 따라 오염 조항으로 순차 치환하였다. 정답 근거를 고정한 이유는 오염이 늘어날 때 정답 근거까지 함께 사라지는 교란을 막아 오답이 발생하면 정답 근거가 없어서가 아닌 오염된 근거로 인한 함이라고 해석할 수 있게 하기 위함이다. 오염 조항은 혼동 강도가 높은 순서로 누적 주입 하였다. (L1<L2<L3<L4). L5 는 정답 근거 없이 5 개 전부를 오염 조항으로 채운 조건으로, 검색이 완전히 실패한 상황에 해당한다.

나. 기권 유도 프롬프트

P0(기본 지시문):“참고자료를 바탕으로 답하세요.”,P1(기권 유도 지시문):위 지시에 더해 “제공된 자료에서 확인할 수 없으면 추측하지 말고 확인할 수 없다고 답하세요” 를 추가하였다. 같은 질문×레벨 조합의 근거 세트는 한 번만 생성하여 P0/P1 이 동일하게 공유하도록 하였다.

다. 4 분류 판정

응답은 정답·근거초과·기권·오답의 4 가지로 분류한다. 근거초과는 핵심 사실은 맞히되 제공된 근거에 없는 내용을 덧붙인 응답으로, 즉각적인 위험은 아니나 검증 부담을 발생시키는 중간 상태다. 측정은 GPT-4o-mini(temperature=0.7)로 각 조건(6 레벨×2 프롬프트)마다 질문당 30 회 응답을 생성하고, 별도 세션의 LLM(temperature=0)이 정답 근거 및 모델이 실제로 받은 근거 전체와 대조해 4 분류로 판정하였다. 답변 생성과 판정을 분리하여 판정 장치가 측정 대상을 오염시키지 않도록 했으며 오염 조항의 고유 수치가 응답에 포함되었는지를 문자열로 직접 확인하는 절차를 병행하여 정답 수치 없이 오염 수치만 제시한 응답은

판정 결과와 무관하게 오답으로 처리하였다.

3. 실험

가. 실험환경 구축

항만안전·시설 규정 문서를 정제·청킹(chunking)하여 ChromaDB 에 적재하였다. (전 항만 공통 문서 2,262 청크, 항만별 전용 문서 469 청크)질문은 8 문항으로, 각 질문마다 정답 조항 1 개와 그에 대응하는 오염 조항 5 개를 사전에 지정하였다. 오염 조항은 같은 문서 안에서 임베딩(embedding) 유사도와 수치 충돌 여부로 후보를 추린 뒤, 원문 대조를 거쳐 해당 질문의 답이 될 수 없음을 확인한 것만 채택하였다. 질문은 동일한 근거 쌍에 대해 단답형(수치 하나를 묻는 형태)과 설명형(항목과 기준을 서술하게 하는 형태)두 가지로 작성하여 질문 형태가 결과에 미치는 영향을 함께 관찰하였다.

나. 실험 결과


표 1 은 오염 조항 주입 개수별 오답률이다(조건당 단답형·설명형 각 240 회).

<표 1> 오염 조항 개수별 오답률


오염	단답 P0	단답 P1	설명 P0	설명 P1
0 개	0.0%	0.0%	0.0%	0.0%
1 개	0.0%	0.0%	0.0%	0.0%
2 개	1.2%	4.2%	0.0%	0.0%
3 개	1.2%	4.6%	0.0%	0.0%
4 개	0.4%	0.0%	0.4%	0.0%
전량*	100.0%	52.9%	86.7%	25.0%

* 정답 근거를 제거하고 5개 전부를 오염 조항으로 채운 조건

정답 근거가 하나라도 남아 있는 구간(오염 0~4 개)에서는 오염 조항을 얼마나 주입하든 오답률이 0~4.6%에 머물렀다. 오염 조항이 정답 조항과 같은 문서에 있고 항목명과 서술 형식까지 거의 동일했음에도 모델은 대부분 정답 조항을 찾아냈다. 반면 정답 근거를 제거한 전량 오염 조건에서는 오답률이 단답형 100.0%, 설명형 86.7%로 급증하였다.(그림 1,2).



(그림 1) 단답형 질문의 오염 개수별 오답률.



(그림 2) 설명형 질문의 오염 개수별 오답률.

전량 오염 조건에서 발생한 오답은 모델이 없는 내용을 지어낸 것이 아니라, 원문에 실재하는 문장을 근거로 주입된 오염 조항의 수치를 그대로 인용한 것이다.

기권 유도 지시문(P1)은 전량 오염 조건에서 오답률을 단답형 52.9%, 설명형 25.0%로 낮추었다. 부분 오염 구간에서는 오답이 거의 발생하지 않아 P0와 P1의 차이가 거의 없었다.

4 분류 채점은 질문 형태에 따른 차이를 드러냈다. 부분 오염 구간에서 단답형은 정답이 99.2%(P0)로 근거초과가 거의 없었던 반면, 설명형은 서술 공간이 주어지면 모델이 핵심 사실을 맞히면서도 제공된 근거에 없는 내용을 덧붙여 근거초과가 27.7%(P0)에 달했다. 기권 유도 지시문은 이 근거초과를 6.1%까지 낮추었다(표 2).

<표 2> 부분 오염 구간(오염 1~4개)의 응답 분포

조건	정답	근거초과	기권	오답
단답 P0	99.2%	0.1%	0.0%	0.7%
단답 P1	97.6%	0.0%	0.2%	2.2%
설명 P0	72.2%	27.7%	0.0%	0.1%
설명 P1	82.8%	6.1%	11.0%	0.0%

다. 고찰

정답 조항이 근거에 포함되어 있는 한 같은 문서의 혼동 조항을 최대 4개까지 주입해도 오답률은 5%미만에 머물렀고, 위험은 정답 근거가 완전히 누락된 구간에서만 발생했다.

정답 근거가 포함된 부분 오염 구간에서 단답형의 정답률은 99.2%에서 97.6%로 낮아졌고, 설명형에서는 답할 수 있는 근거가 있음에도 11.0%가 기권하였다. 즉 검색이 정상적으로 작동하는 구간에서는 이득 없이 손실만 발생한다. 기권 유도 프롬프트는 항상 적용하는 기본 설정이 아니라, 검색 결과의 신뢰도가 낮다고 판단될 때 선택적으로 적용하는 안전장치로 운용하는 것이 적절하다.

4. 결론

본 연구에서는 항만 안전 규정 RAG에서 근거 오염이 응답에 미치는 영향을 측정하고, 기권 유도 프롬프트의 방어 효과를 검증하였다. 실험 결과, 정답 근거가 포함된 부분 오염 구간에서는 오답률이 0~4.6%에 머물렀으나, 정답 근거가 없는 전량 오염 조건에서는 오답률이 단답형 100.0%, 설명형 86.7%로 급증하였다. 기권 유도 프롬프트는 전량 오염 조건의 오답률을 단답형 52.9%, 설명형 25.0%로 낮추었으나, 부분 오염 구간에서는 설명형 응답의 11.0%가 불필요하게 기권하였다.

아울러 질문 수와 대상 항만을 확대하고, 검색 결과의 신뢰도를 추정하여 기권 유도 지시문을 조건부로 적용하는 방식이 상시 적용 대비 정답률 손실 없이 위험 구간만 방어할 수 있는지를 향후 연구에서 검증할 예정이다.

ACKNOWLEDGEMENT

본 논문은 해양수산부 스마트 해운물류 융합인재 및 기업지원(스마트해운물류×ICT 멘토링)을 통해 수행한 ICT 멘토링 프로젝트 결과물입니다

참고문헌

- [1] P. Lewis, E. Perez, A. Piktus, et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems (NeurIPS), Virtual, 2020, pp. 9459–9474.
- [2] F. Shi, X. Chen, K. Misra, et al., "Large Language Models Can Be Easily Distracted by Irrelevant Context," Proceedings of the 40th International Conference on Machine Learning (ICML), Honolulu, USA, 2023, pp. 31210–31227.
- [3] J. Xie, K. Zhang, J. Chen, R. Lou, Y. Su, "Adaptive Chameleon or Stubborn Sloth: Revealing the Behavior of Large Language Models in Knowledge Conflicts," International Conference on Learning Representations (ICLR), Vienna, Austria, 2024.
- [4] J. Chen, H. Lin, X. Han, L. Sun, "Benchmarking Large Language Models in Retrieval-Augmented Generation," Proceedings of the AAAI Conference on Artificial Intelligence, Vancouver, Canada, 2024, pp. 17754–17762.
- [5] W. Zou, R. Geng, B. Wang, J. Jia, "PoisonedRAG: Knowledge Corruption Attacks to Retrieval-Augmented Generation of Large Language Models," 34th USENIX Security Symposium, Seattle, USA, 2025, pp. 3827–3844.
- [6] S. Feng, W. Shi, Y. Wang, W. Ding, V. Balachandran, Y. Tsvetkov, "Don't Hallucinate, Abstain: Identifying LLM Knowledge Gaps via Multi-LLM Collaboration," Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL), Bangkok, Thailand, 2024, pp. 14664–14690.